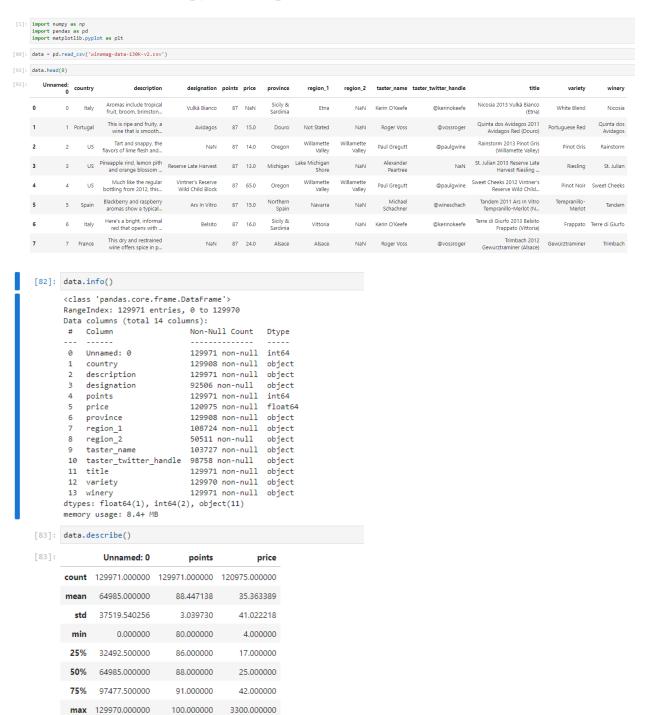
ВАРИАНТ 11

Набор данных содержит список Вин. Используются данные из https://www.kaggle.com/datasets/zynicide/wine-reviews

Загрузка и первичный анализ данных



data[['d	ountry',	'points', 'region_1', 'variety']]				
	country	points	region_1	variety		
0	Italy	87	Etna	White Blend		
1	Portugal	87	NaN	Portuguese Red		
2	US	87	Willamette Valley	Pinot Gris		
3	US	87	Lake Michigan Shore	Riesling		
4	US	87	Willamette Valley	Pinot Noir		
129966	Germany	90	NaN	Riesling		
129967	US	90	Oregon	Pinot Noir		
129968	France	90	Alsace	Gewürztraminer		
129969	France	90	Alsace	Pinot Gris		
129970	France	90	Alsace	Gewürztraminer		

129971 rows × 4 columns

Задание №11

Для набора данных проведите устранение пропусков для одного (произвольного) категориального признака с использованием метода заполнения отдельной категорией для пропущенных значений.

В качестве произвольного признака выберем колонку "region_1". Затем заменим пропущенные значения категорией "Not Stated"

```
[87]: data['region_1'].fillna('Not Stated', inplace = True)

[88]: data['region_1'].isna().sum()

[88]: 0

[89]: data.head(20)
```

91]:	data[dat	ta['region_1'] == 'N	ot Stated'][['country', 'points',
1]:		country	points	region_1	variety
	1	Portugal	87	Not Stated	Portuguese Red
	8	Germany	87	Not Stated	Gewürztraminer
	15	Germany	87	Not Stated	Riesling
	36	Chile	86	Not Stated	Viognier-Chardonnay
	44	Chile	86	Not Stated	Merlot
	129956	New Zealand	90	Not Stated	Bordeaux-style Red Blend
	129958	New Zealand	90	Not Stated	Bordeaux-style Red Blend
	129960	Portugal	90	Not Stated	Pinot Noir
	129963	Israel	90	Not Stated	Cabernet Sauvignon
	129966	Germany	90	Not Stated	Riesling

21247 rows × 4 columns

Заметим, что все пропущенные значения были успешно заменены на "Not Stated"

Задание №31

Для набора данных проведите процедуру отбора признаков (feature selection). Используйте метод обертывания (wrapper method), прямой алгоритм (sequential forward selection).

```
[13]: import numpy as np
      import pandas as pd
      import matplotlib.pyplot as plt
      import seaborn as sns
[14]: data = pd.read_csv("KNNAlgorithmDataset.csv")
[15]: data[['diagnosis', 'radius_mean', 'texture_mean', 'perimeter_mean', 'area_mean', 'compactness_mean']]
            diagnosis radius_mean texture_mean perimeter_mean area_mean compactness_mean
         0
                   М
                             17.99
                                           10.38
                                                           122.80
                                                                      1001.0
                                                                                         0.27760
                             20.57
                                           17.77
                                                           132.90
                                                                      1326.0
                                                                                         0.07864
                                           21.25
                                                           130.00
                                                                      1203.0
                                                                                         0.15990
                             19.69
                                           20.38
                   М
                             11.42
                                                            77.58
                                                                       386.1
                                                                                        0.28390
         4
                   М
                             20.29
                                           14.34
                                                           135.10
                                                                      1297.0
                                                                                        0.13280
       564
                             21.56
                                           22.39
                                                           142.00
                                                                      1479.0
                                                                                         0.11590
       565
                             20.13
                                           28.25
                                                           131.20
                                                                      1261.0
                                                                                         0.10340
       566
                             16.60
                                           28.08
                                                           108.30
                                                                       858.1
                                                                                         0.10230
                   М
       567
                             20.60
                                           29.33
                                                           140.10
                                                                      1265.0
                                                                                         0.27700
       568
                              7.76
                                           24.54
                                                            47.92
                                                                       181.0
                                                                                         0.04362
      569 rows × 6 columns
 [ ]: from sklearn.neighbors import KNeighborsClassifier
      from mlxtend.feature_selection import SequentialFeatureSelector as SFS
```

Выберем "diagnosis" для предсказания прогноза

```
[ ]: X = data.drop(labels = 'diagnosis', axis = 1).copy(deep = True)
Y = data['diagnosis'].copy(deep = True)
knn = KNeighborsClassifier(n_neighbors=5)
sfs = SFS(knn, forward = True, floating = False, k_feature = 4)
[ ]: sfs.fit(X,Y)
```

```
► SequentialFeatureSelector

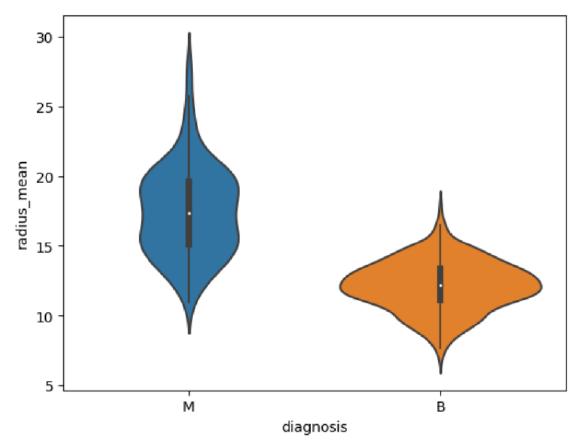
► estimator: KNeighborsClassifier

► KNeighborsClassifier
```

```
[ ]: sfs.subsets_
{1: {'feature_idx': (7,),
  'cv scores': array([0.86842105, 0.9122807 , 0.9122807 , 0.92982456, 0.90265487]),
  'avg score': 0.9050923769600994,
  'feature names': ('concave points_mean',)},
 2: {'feature idx': (7, 16),
  'cv_scores': array([0.92105263, 0.93859649, 0.90350877, 0.93859649, 0.90265487]),
  'avg score': 0.9208818506443098,
  'feature_names': ('concave points_mean', 'concavity_se')},
 3: {'feature_idx': (7, 16, 20),
  'cv_scores': array([0.85087719, 0.92105263, 0.93859649, 0.94736842, 0.9380531 ]),
  'avg score': 0.9191895668374475,
  'feature_names': ('concave points_mean', 'concavity_se', 'radius_worst')},
 4: {'feature_idx': (7, 16, 20, 26),
  'cv_scores': array([0.92105263, 0.92982456, 0.95614035, 0.93859649, 0.94690265]),
  'avg_score': 0.9385033379909953,
  'feature names': ('concave points mean',
   'concavity_se',
   'radius_worst',
   'concavity_worst')}}
```

Наилучшая точность достигается при выборе признаков 'concave points mean', 'concavity se', 'radius worst', 'concavity worst'





Задание для группы ИУ5-25М - для произвольной колонки данных построить парные диаграммы (pairplot).



<seaborn.axisgrid.PairGrid at 0x7fdb7e69cd30>

